

大数据机器学习第十次理论作业

常智星 2024214438

2026 年 1 月 22 日

一、 试求矩阵 $A = \begin{bmatrix} 2 & 4 \\ 1 & 3 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$ 的奇异值分解并写出其外积展开式。

1. 问题分析与相关知识点

1). 奇异值分解

矩阵的奇异值分解是指，将一个非零的 $m \times n$ 实矩阵 A , $A \in R^{m \times n}$, 表示为以下三个实矩阵乘积形式的运算，即进行矩阵的因子分解：

$$A = U\Sigma V^T \quad (1)$$

其中， U 是 m 阶正交矩阵， V 是 n 阶正交矩阵， Σ 是由降序排列的非负对焦线元素组成的 $m \times n$ 矩形对角矩阵，满足：

$$UU^T = I$$

$$VV^T = I$$

$$\Sigma = (\sigma_1, \sigma_2, \dots, \sigma_p)$$

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq 0$$

$$p = \min(m, n)$$

其中， $U\Sigma V^T$ 称为矩阵的奇异值分解 (singular value decomposition, SVD); σ_i 称为矩阵的奇异值； U 的列向量称为左奇异向量， V 的列向量称为右奇异向量。

2). 矩阵的基本子空间

I. 向量子空间

若 S 是向量空间 V 的非空子集，且 S 满足以下条件：

i. 对任意实数 a ，若 $x \in S$ ，则 $ax \in S$ ；

ii. 若 $x \in S$ 且 $y \in S$ ，则 $x + y \in S$ ；

则 S 称为 V 的子空间。

设 v_1, v_2, \dots, v_n 为向量空间 V 中的向量，则其线性组合

$$a_1 v_1 + a_2 v_2 + \dots + a_n v_n$$

构成 V 的子空间，称 v_1, v_2, \dots, v_n 张成的子空间，或 v_1, v_2, \dots, v_n 的张成，记为：

$$\text{span}(v_1, v_2, \dots, v_n)$$

如果 $\text{span}\{v_1, v_2, \dots, v_n\} = V$ ，则称 v_1, v_2, \dots, v_n 张成 V 。

II. 向量空间的基和维数

向量空间 V 中向量 v_1, v_2, \dots, v_n 称为空间 V 的基，如果满足条件：

- i. v_1, v_2, \dots, v_n 线性无关；
- ii. v_1, v_2, \dots, v_n 张成 V ；

向量空间基的个数即向量空间的维数。

III. 矩阵的行空间和列空间

设 A 为一个 m 行 n 列 $m \times n$ 的矩阵，其每一行可以看作 R^n 中的一个向量，称为 A 的行向量；类似地，其每一列可以看作 R^m 中的一个向量，称为 A 的列向量。

设 A 为一个 m 行 n 列 $m \times n$ 的矩阵，则由 A 的行向量张成的 R^n 的子空间，称为 A 的行空间；由 A 的列向量张成的 R^m 的子空间，称为 A 的列空间。

矩阵 A 的行空间的维数等于列空间的维数，称为矩阵的秩。

IV. 矩阵的零空间

设 A 为一个 m 行 n 列 $m \times n$ 的矩阵，令 $N(A)$ 为齐次方程组 $Ax = 0$ 的所有解的集合，则 $N(A)$ 为 R^n 的一个子空间，称为 A 的零空间 (null space)：

$$N(A) = \{x \in R^n | Ax = 0\} \quad (2)$$

一个矩阵零空间的维数称为矩阵的零度。

【秩-零度定理】 设 A 为一 $m \times n$ 的矩阵，则 A 的秩和 A 的零度之和为 n 。若 A 的秩为 r ，则方程组 $Ax = 0$ 的独立变量有 r 个，自由变量有 $n - r$ 个。

V. 子空间的正交补

设 X 和 Y 为 R^n 的子空间。若对每一个 $x \in X$ 和 $y \in Y$ 都满足 $x^T y = 0$ ，则称 X 和 Y 是正交的，记作 $X \perp Y$ 。

令 Y 为 R^n 的子空间， R^n 中与 Y 中的每一个向量都正交的向量集合记为 Y^\perp ，即

$$Y^\perp = \{x \in R^n | x^T y = 0, \forall y \in Y\}$$

集合 Y^\perp 称为 Y 的正交补。

VI. 矩阵的基本子空间

设 A 为一 $m \times n$ 的矩阵，可以把 A 看成是将 R^n 映射到 R^m 的线性变换。一个向量 $z \in R^m$ 在 A 的列空间的充要条件是存在 $x \in R^n$ ，使得 $z = Ax$ 。这样 A 的列空间和 A 的值域是相同的。记 A 的值域为 $R(A)$ ，则：

$$\begin{aligned} R(A) &= \{x \in R^m | \exists x \in R^n, z = Ax\} \\ &= A \text{ 的列空间} \end{aligned}$$

类似地，一个向量 $y \in R^n$ ， y^T 在 A 的行空间的充要条件是 $\exists x \in R^m$ ，使得 $y = A^T x$ 。这样 A 的行空间和 A^T 的值域 $R(A^T)$ 是相同的。

$$\begin{aligned} R(A^T) &= \{y \in R^n | \exists x \in R^m, y = A^T x\} \\ &= A \text{ 的行空间} \end{aligned}$$

VII. 矩阵的基本子空间

矩阵有 4 个基本子空间：列空间、行空间、零空间、 A 的转置的零空间（左零空间），其关系如图 1 所示。

矩阵的基本子空间之间的关系

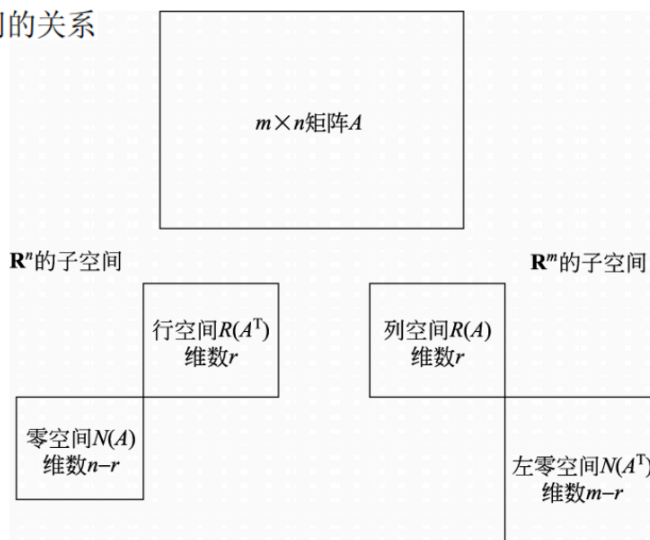


图 1: 矩阵的基本子空间的关系

有下面的定理成立：

【定理 1】若 A 为一 $m \times n$ 的矩阵，则 $N(A) = R(A^T)^\perp$ ，且 $N(A^T) = R(A)^\perp$ 。

3). 矩阵奇异值分解的计算

I. 求 $A^T A$ 的特征值和特征向量：

$$W = A^T A$$

$$(W - \lambda I)x = 0$$

得到特征值 λ_i ，并将特征值从大到小排列：

$$\lambda_1 \geq \lambda_2 \geq \cdots \lambda_n \geq 0$$

并将特征值 $\lambda_i (i = 1, 2, \cdots, n)$ 代入特征方程求得对应的特征向量。

II. 求 n 阶正交矩阵 V ：将特征向量单位化得到单位特征向量 v_1, v_2, \cdots, v_n ，构成 n 阶正交矩阵 V ：

$$V = \begin{bmatrix} v_1 & v_2 & \cdots & v_n \end{bmatrix}$$

III. 求 $m \times n$ 对角矩阵 Σ ：计算 A 的奇异值：

$$\sigma_i = \sqrt{\lambda_i}, \quad i = 1, 2, \cdots, n$$

构造 $m \times n$ 对角矩，主对角线元素是奇异值，其余元素为 0:

$$\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$$

IV. 求 m 阶正交矩阵 U : 对 A 的前 r 个正奇异值，令:

$$u_j = \frac{1}{\sigma_j} A v_j, \quad j = 1, 2, \dots, r$$

得到

$$U_1 = \begin{bmatrix} u_1 & u_2 & \cdots & u_r \end{bmatrix}$$

求 A^T 的零空间的一组标准正交基 $\{u_{r+1}, u_{r+2}, \dots, u_m\}$, 令

$$U_2 = \begin{bmatrix} u_{r+1} & u_{r+2} & \cdots & u_m \end{bmatrix}$$

并令

$$U = \begin{bmatrix} U_1 & U_2 \end{bmatrix}$$

V. 得到奇异值分解:

$$A = U \Sigma V^T$$

4). 矩阵的外积展开式

矩阵的奇异值分解 $U \Sigma V^T$ 也可以由外积形式表示。如果把 A 的奇异值分解，看成矩阵 $U \Sigma$ 和 V^T 的乘积，将 $U \Sigma$ 按列向量分块，将 V^T 按行向量分块，即得到:

$$U \Sigma = \begin{bmatrix} \sigma_1 u_1 & \sigma_2 u_2 & \cdots & \sigma_n u_n \end{bmatrix}$$

$$V^T = \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_n^T \end{bmatrix}$$

则 A 的外积展开式:

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \sigma_n u_n v_n^T$$

即:

$$u_i v_j^T = \begin{bmatrix} u_{1i} \\ u_{2i} \\ \vdots \\ u_{mi} \end{bmatrix} \begin{bmatrix} v_{1j} & v_{2j} & \cdots & v_{nj} \end{bmatrix} = \begin{bmatrix} u_{1i} v_{1j} & u_{1i} v_{2j} & \cdots & u_{1i} v_{nj} \\ u_{2i} v_{1j} & u_{2i} v_{2j} & \cdots & u_{2i} v_{nj} \\ \vdots & \vdots & \vdots & \vdots \\ u_{mi} v_{1j} & u_{mi} v_{2j} & \cdots & u_{mi} v_{nj} \end{bmatrix}$$

A 的外积展开式也可以写为:

$$A = \sum_{k=1}^n A_k = \sum_{k=1}^n \sigma_k u_k v_k^T$$

由 A 的外积展开式可知，若 A 的秩为 n ，则:

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \sigma_n u_n v_n^T$$

设矩阵

$$A_k = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \sigma_k u_k v_k^T$$

则 A_k 的秩为 k ，并且 A_k 是秩为 k 的矩阵在弗罗贝尼乌斯范数意义 A 的最优近似矩阵，矩阵 A_k 就是 A 的截断奇异值分解。由于通常奇异值 σ_i 递减很快，所以 k 取很小时， A_k 也能对 A 有很好的近似。

2. 问题求解

1). 求矩阵的奇异值分解

I. 求 $A^T A$ 的特征值和特征向量:

$$A^T A = \begin{bmatrix} 2 & 1 & 0 \\ 4 & 3 & 0 \end{bmatrix} \begin{bmatrix} 2 & 4 \\ 1 & 3 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 5 & 11 \\ 11 & 25 \end{bmatrix}$$

特征值和特征向量满足方程:

$$(A^T A - \lambda I)x = 0$$

得到其次线性方程组:

$$\begin{cases} (5 - \lambda)x_1 + 11x_2 = 0 \\ 11x_1 + (25 - \lambda)x_2 = 0 \end{cases}$$

方程组有解的充要条件是行列式 $\begin{vmatrix} 5 - \lambda & 11 \\ 11 & 25 - \lambda \end{vmatrix} = 0$

即

$$(5 - \lambda)(25 - \lambda) - 121 = \lambda^2 - 30\lambda + 4 = 0$$

可求解得到特征值 λ_i , 并将特征值从大到小排列:

$$\lambda_1 = 15 + \sqrt{221}, \quad \lambda_2 = 15 - \sqrt{221}$$

为方便计算, 使用代码进行后续求解。

II. 代码实现

```
import numpy as np
from scipy.linalg import null_space

# 初始化A矩阵
A = np.array([[2,4],[1,3],[0,0],[0,0]],dtype= float)
m,n = A.shape

# 计算A的转置乘A, 并求特征值、特征向量
ATA = np.array(A.T@A)
ATA_value,ATA_vector = np.linalg.eig(ATA)

# 对特征值按降序排序
argsort_value_index = np.argsort(-ATA_value)
ATA_sort_value = ATA_value[argsort_value_index]
# 按特征值降序排序特征向量作为V矩阵列向量并将其转置的VT矩阵
VT = ATA_vector[argsort_value_index]
print(f'V^T:\n{VT}')
# 对特征值取根号获取奇异值
sigma_list = []
for i in range (0,ATA_sort_value.shape[0]):
    value = np.sqrt(ATA_sort_value[i])
    sigma_list.append(value)
print(f'奇异值:\n{sigma_list}')
```

```

# 构造m*n对角矩阵sigma_matrix
sigma_matrix = np.zeros((m,n))
sigma_matrix[:, len(sigma_list): len(sigma_list)] = np.diag(sigma_list)
print(f'对角矩阵:\n{sigma_matrix}')

# 计算U矩阵
U = np.zeros((m,m)) # 初始化U矩阵
for i in range(m):
    # 计算U1
    if i < len(sigma_list) and (sigma_list[i]>0):
        # i<=r时 计算u_j = 1/sigma_j*A*v_j
        u_j = 1/sigma_list[i] * (A@ VT[i])
        U[i] = u_j
    # 计算U2
    else:
        # i>r时 计算U2为A^T的零空间的标准正交基
        U2 = null_space(A.T).T
        for j in range( len(U2)):
            U[i] = U2[j]
        break
# 转置得到U矩阵
U= U.T
print(f'U:\n{U}')

A_res = U@sigma_matrix@VT
# 验证结果
print(f'U * Sigma * V^T :\n{A_res}')
print(f'A:\n{A}')

```

结果

V^T:

```
[[ 0.40455358 -0.9145143 ]
 [-0.9145143 -0.40455358]]
```

奇异值:

```
[5.464985704219043, 0.3659661906262547]
```

对角矩阵:

```
[[5.4649857  0.          ]
 [0.          0.36596619]
 [0.          0.          ]
 [0.          0.          ]]
```

U:

```
[[-0.52130969 -9.41956667  0.          0.          ]
 [-0.4279955  -5.81522311  0.          0.          ]
 [ 0.          0.          0.          0.          ]
 [ 0.          0.          1.          0.          ]]
```

U * Sigma * V^T :

```
[[2. 4.]
 [1. 3.]
 [0. 0.]
 [0. 0.]]
```

```
A:
[[2. 4.]
 [1. 3.]
 [0. 0.]
 [0. 0.]]
```

2). 外积展开式表示

根据上面的计算结果可知：

$$\sigma_1 = 5.4650, \quad \sigma_2 = 0.3660$$

$$v_1^T = \begin{bmatrix} 0.4046 & -0.9145 \end{bmatrix}, \quad v_2^T = \begin{bmatrix} -0.9145 & 0.4046 \end{bmatrix}$$

$$u_1 = \begin{bmatrix} -0.5213 \\ -0.4280 \end{bmatrix}, \quad u_2 = \begin{bmatrix} -9.4196 \\ -5.8152 \end{bmatrix}$$

A 的外积展开式：

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T$$

代码实现

```
# 外积展开式
# A = sigma_1u_1v_1^T+sigma_2u_2v_2^T
A_outer = sigma_list[0]*np.outer(U[:,0],VT[0,:])+sigma_list[1]*np.outer(U[:,1],VT[1,:])
print(f'A外积展开式计算结果:\n{A_outer}')
```

结果

A外积展开式计算结果：

```
[[ 2.  4.]
 [ 1.  3.]
 [ 0. -0.]
 [ 0. -0.]]
```

二、 搜索中的点击数据记录用户搜索时提交的查询语句, 点击的网页 URL 以及点击的次数构成一个二部图, 其中一个结点集合 $\{q_i\}$ 表示查询, 另一个结点集合 $\{u_j\}$ 表示 URL, 边表示点击关系, 边上的权重表示点击次数。图 15.2 是一个简化的点击数据例。点击数据可以由矩阵表示, 试对该矩阵进行奇异值分解, 并解释得到的三个矩阵所表示的内容




图15.2 搜索点击数据例

1. 问题求解

1). 写出二部图对应的矩阵 A

$$A = \begin{matrix} & \begin{matrix} u_1 & u_2 & u_3 & u_4 & u_5 \end{matrix} \\ \begin{matrix} q_1 \\ q_2 \\ q_3 \\ q_4 \end{matrix} & \begin{bmatrix} 0 & 20 & 5 & 0 & 0 \\ 10 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 \end{bmatrix} \end{matrix}$$

2). 求矩阵 A 的奇异值分解:

```
import numpy as np

A= [[0,20,5,0,0],[10,0,0,3,0],[0,0,0,0,1],[0,0,1,0,0]]
np.set_printoptions(precision=6,suppress=True)
U,sigma_matrix,V = np.linalg.svd(A)
print(f'U:\n{U}')
print(f'Sigma:\n{sigma_matrix}')
print(f'V:\n{V.T}')
```

结果

```
U:
[[ 0.99993 -0.      0.      -0.01179]
 [ 0.      1.      0.      -0.      ]
 [ 0.      0.      1.      0.      ]
 [ 0.01179 0.      0.      0.99993]]

Sigma:
[20.616958 10.440307 1.      0.970075]
```


V:

```
[[ 0.          0.957826 -0.          -0.          0.287348]
 [ 0.970008 -0.          0.          -0.243074 -0.          ]
 [ 0.243074  0.          0.          0.970008  0.          ]
 [ 0.          0.287348  0.          0.          -0.957826]
 [ 0.          0.          1.          0.          0.          ]]
```

3). 分析 3 个矩阵代表的含义

I. 矩阵 Σ : 表示每个网页特征的重要程度。

II. 矩阵 V : V 的列向量表示每个 URL 与每个网页特征之间的关系。

矩阵 V 的第 1 列表示 URL1 的第 2 个特征较显著；第 2 列表示 URL2 的第 1 个特征较显著。

III. 矩阵 U : U 的列向量表示每个查询和每个网页特征之间的对应关系。

矩阵 U 的第 1 列表示第 1 个查询倾向于第 1 个特征较显著的 URL，即 URL2；矩阵 U 的第 2 列表示第 2 个查询倾向于第 2 个特征较显著的 URL，即 URL1。